《法律实证分析》期中 cheat sheet

Peking University · Abdey Shun Chang

1. 实证法学方法论与因果推断架构

1.1 事实学转向与休谟二分定理

- **休谟准则 (Hume's Guillotine)**：严格区隔“实然”(Is, 经验事实)与“应然”(Ought, 规范价值)。从纯粹事实前提不能演绎出规范结论；规范有效性亦不等于实效性。
- **实证法学的论证功能**：
  - **描述性论证**：识别司法场域的总体经验分布（如量刑基准、法官群体裁判均值与离散度）。
  - **目的论证 (Teleological)**：评估法规范配置能否有效达成刑罚威慑、犯罪预防等立法目的。
  - **结果论证 (Consequential)**：识别制度运行的负外部性与意外后果（如重刑带来的残忍化效应）。

1.2 潜在结果模型与因果识别策略

- **鲁宾因果模型 (Rubin Causal Model)**：设处理变量 $D_i \in \{0,1\}$，个体 i 的潜在结果为 $Y_i(1), Y_i(0)$。观测结果为 $Y_i = D_i Y_i(1) + (1 - D_i) Y_i(0)$。
- **选择偏差分解**：

$$E[Y|D=1] - E[Y|D=0] = \underbrace{E[Y(1) - Y(0) \mid D=1]}_{\text{处理组平均效应 (ATT)}} + \underbrace{\{E[Y(0)|D=1] - E[Y(0)|D=0]\}}_{\text{选择偏差 (Selection Bias)}}$$

- **随机对照实验 (RCT)**：通过随机分配实现协变量平衡 $D \perp (Y(1), Y(0))$，选择偏差期望为零。司法应用受制于正当程序与伦理。
- **准实验 (Quasi-Experiments)**：利用外生冲击（如指定辩护全覆盖试点、选举周期治安官扩招），采用 DID、断点回归 (RD)、倾向得分匹配 (PSM) 剥离混杂偏误。

2. 测度理论与数据生成机制

2.1 变量测度等级体系

从低阶到高阶递进，高阶变量包含低阶变量的全部代数信息：

1. **定类 (Nominal)**：仅满足等价关系 $(=, \neq)$。支持众数统计、列联表卡方检验与哑变量转换（如性别、罪名类型）。
2. **定序 (Ordinal)**：满足全序关系 $(<, >)$，但距离非等距。支持秩次与中位数，差值无运算意义（如李克特量表、伤情等级）。
3. **定距 (Interval)**：具有等距单位，差值具代数意义，**无绝对真零点**（零点为任意人为标定，如摄氏温度）。
4. **定比 (Ratio)**：具有等距单位且**具备绝对自然零点**（零代表属性完全缺失），支持乘除比率运算（如刑期、罚金额、酒精浓度）。

2.2 数据集的时间维度分类

- **横截面数据 (Cross-sectional)**：单一时点 t 对 n 个独立个体的静态切片 $\{Y_i, \boldsymbol{X}_i\}_{i=1}^n$。
- **重复横截面 (Pooled Cross-sectional)**：不同时点独立抽样，个体不跨期重合。用于评估改革前后的平均处理效应。
- **时间序列数据 (Time Series)**：单一个体在离散时间轴上的连续观测 $\{Y_t\}_{t=1}^T$。
- **面板数据 (Panel Data)**：追踪相同截面个体在连续时期的复合观测 $\{Y_{it}, \boldsymbol{X}_{it}\}_{i=1,t=1}^{n,T}$。

2.3 抽样设计理论

- **简单随机抽样 (SRS)**：样本入选概率相同且完全独立。
- **分层抽样 (Stratified Sampling)**：层内同质、层间异质，按比例配额。严格消除层间变异带来的抽样误差。
- **整群抽样 (Cluster Sampling)**：群间同质、群内异质。群内聚类相关性会导致有效样本容量萎缩，须调整聚类标准误。

3. 描述性统计量与点估计理论

3.1 集中趋势与偏度法则

设样本观测序列为 $X_1, X_2, \ldots, X_n$：

- **样本均值**：$\bar{X} = \frac{1}{n}\sum_{i=1}^n X_i$。满足 $E[\bar{X}] = \mu$，为总体均值的一致最小方差无偏估计 (UMVUE)。易受极端值拖拽。
- **样本中位数 (Median)**：稳健统计量，崩溃点 (Breakdown Point) 达 50%。
- **偏度分布测度 (Skewness)**：
  - 正偏（右偏，长尾在右侧，如财产刑罚金）：Mode < Median < Mean
  - 对称单峰分布（正态）：Mean = Median = Mode
  - 负偏（左偏，长尾在左侧）：Mean < Median < Mode

3.2 离散程度与 Bessel 修正证明

- **总体方差 vs 样本方差**：

$$\sigma^2 = \frac{1}{N}\sum_{i=1}^N (X_i - \mu)^2, \quad S^2 = \frac{1}{n-1}\sum_{i=1}^n (X_i - \bar{X})^2$$

- **无偏性证明**：展开离差平方和恒等式：

$$\sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=1}^n (X_i - \mu)^2 - n(\bar{X} - \mu)^2$$

两端求期望，利用 $E[(X_i - \mu)^2] = \sigma^2$ 以及 $\mathrm{Var}(\bar{X}) = E[(\bar{X} - \mu)^2] = \frac{\sigma^2}{n}$：

$$E\left[\sum_{i=1}^n (X_i - \bar{X})^2\right] = n\sigma^2 - n\left(\frac{\sigma^2}{n}\right) = (n-1)\sigma^2$$

故 $E[S^2] = \frac{1}{n-1}(n-1)\sigma^2 = \sigma^2$。分母扣除 1 自由度消除低估偏差。

- **仿射变换性质**：若 $Y = aX + b$，则 $\bar{Y} = a\bar{X} + b$，$S_Y = |a| S_X$，$S_Y^2 = a^2 S_X^2$。
- **标准分化 (Z-Transformation)**：$Z_i = \frac{X_i - \mu}{\sigma}$，具有性质 $E[Z_i] = 0, \mathrm{Var}(Z_i) = 1$。

4. 大数定律、中心极限定理与区间估计

4.1 正态分布代数性质与分位数

随机变量 $X \sim \mathcal{N}(\mu, \sigma^2)$，累积分布函数为 $\Phi\left(\frac{x-\mu}{\sigma}\right)$。

- 对称性质：$\Phi(-z) = 1 - \Phi(z)$。
- 经验法则：$P(|X-\mu| \le 1\sigma) \approx 0.6827$; $P(|X-\mu| \le 1.96\sigma) \approx 0.9500$; $P(|X-\mu| \le 2.576\sigma) \approx 0.9900$。

4.2 渐近收敛理论 (CLT & Slutsky 定理)

- **Lindeberg-Lévy 中心极限定理**：设 $X_1, \ldots, X_n \overset{\text{i.i.d.}}{\sim} (\mu, \sigma^2)$ $(0 < \sigma^2 < \infty)$（无须正态假设），当 $n \to \infty$ 时：

$$\sqrt{n}(\bar{X}_n - \mu) \xrightarrow{d} \mathcal{N}(0, \sigma^2) \iff \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} \mathcal{N}(0,1)$$

- **Slutsky 渐近替代定理**：由大数定律 $S_n \xrightarrow{P} \sigma$，根据 Slutsky 定理：

$$Z = \frac{\bar{X}_n - \mu}{S_n/\sqrt{n}} = \left(\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}}\right) \cdot \left(\frac{\sigma}{S_n}\right) \xrightarrow{d} \mathcal{N}(0,1)$$

在大样本下，即使总体非正态，构造的标准误仍能保证渐近正态推断。

- **标准误 (Standard Error)**：$\mathrm{SE}(\bar{X}) = \frac{\sigma}{\sqrt{n}}$, if σ 已知，otherwise 用 S_n 替代。反映估计量自身的抽样方差，以速率 $O(n^{-1/2})$ 随样本量收敛。

4.3 枢轴量法构造置信区间

- **数理构造**：构造枢轴量（有其分布，不依赖于参数）$Q(\boldsymbol{X}, \mu) = \frac{\bar{X}-\mu}{S/\sqrt{n}}$。双侧 $100(1-\alpha)\%$ 置信区间为满足 $P(c_1 \le Q \le c_2) = 1 - \alpha$ 的解：

$$\mathrm{CI}_{1-\alpha}(\mu) = \left[\bar{X} - z_{\alpha/2}\frac{S}{\sqrt{n}}, \quad \bar{X} + z_{\alpha/2}\frac{S}{\sqrt{n}}\right]$$

- **频率学派概率语义**：区间端点 $[L(\boldsymbol{X}), U(\boldsymbol{X})]$ 是随机变量，真实参数 μ 是固定常数。在无限次重复抽样生成的区间序列中，覆盖真值 μ 的频率收敛于 $1 - \alpha$。

5. 假设检验理论与 Neyman-Pearson 范式

5.1 参数空间划分与反证推断

- 参数空间严格正交分解：$\Theta = \Theta_0 \cup \Theta_a$，且 $\Theta_0 \cap \Theta_a = \emptyset$。

- 原假设 $H_0:\theta\in\Theta_0$；备择假设 $H_a:\theta\in\Theta_a$。
- 检验统计量 $T(\boldsymbol{X})$ 将样本空间映射至实数轴，基于预设的拒绝域 $\mathcal{W}$ 给出二元推断规则：$T(\boldsymbol{x})\in\mathcal{W}\iff$ 拒绝H_0。

5.2 两类错误、势函数与决策控制

定义检验的势函数 (Power Function) 为 $\pi(\theta)=P_\theta(\boldsymbol{X}\in\mathcal{W})$。

统计决策	H_0 为真 ($\theta\in\Theta_0$)	H_a 为真 ($\theta\in\Theta_a$)
接受 H_0	正确接受 $(1-\alpha)$	II 类错误: 取伪 $(\beta(\theta))$
拒绝 H_0	**I 类错误: 弃真 (α)**	检验功效 (Power): $1-\beta(\theta)$

- **显著性水平控制**：$\sup_{\theta\in\Theta_0}\pi(\theta)\le\alpha$。在优先控制 I 类错误概率的前提下，最大化功效 $1-\beta$。
- **两类错误权衡**：样本量 n 固定时，$\alpha\downarrow\implies\beta\uparrow$。唯一能同步压低 α 与 β 的路径是增加样本容量 n。

5.3 p-值与对偶定理

- **p-值的测度论定义**：在零假设为真的概率测度下，检验统计量比实际观测值更极端的上确界概率：

$$p\text{-value}=P_{H_0}\left(|T|\ge|t_{\text{obs}}|\right)$$

  若 H_0 为真且统计量连续，则随机变量 $P\sim\text{Uniform}(0,1)$。
- **对偶定理 (Duality Theorem)**：在显著性水平 α 下，非拒绝域等于置信水平为 $1-\alpha$ 的置信集合之集：

$$\text{未拒绝}H_0:\theta=\theta_0\iff\theta_0\in\text{CI}_{1-\alpha}$$

6. t 检验数理体系 (Student's & Welch)

6.1 Student's t 分布构造

若 $Z\sim\mathcal{N}(0,1)$，$V\sim\chi^2(k)$，且 $Z\perp V$，定义统计量：

$$T=\frac{Z}{\sqrt{V/k}}\sim t(k)$$

对于正态母体样本，由 Cochran 定理，样本均值 $\bar{X}\perp S^2$ 且 $\frac{(n-1)S^2}{\sigma^2}\sim\chi^2(n-1)$。将 $Z=\frac{\bar{X}-\mu}{\sigma/\sqrt{n}}$ 与 $V=\frac{(n-1)S^2}{\sigma^2}$ 代入，消去未知参数 σ，即严格导出 $t(n-1)$ 分布。

6.2 单样本 t 检验 (One-Sample t-Test)

- 满足 $X_1,X_2,\dots,X_n\overset{\text{i.i.d.}}{\sim}N(\mu,\sigma^2)$，$\sigma$ 未知
- 假设：$H_0:\mu=\mu_0$ vs $H_a:\mu\neq\mu_0$
- 统计量：$t=\frac{\bar{X}-\mu_0}{S/\sqrt{n}}\sim t(n-1)$
- 临界拒绝准则：$|t|>t_{\alpha/2,\,n-1}$。

6.3 独立双样本 t 检验 (Two-Sample t-Test)

检验两独立正态总体差值：$H_0:\mu_1-\mu_2=\Delta_0$。

1. **方差齐性假定 ($\sigma_1^2=\sigma_2^2=\sigma^2$)**：采用合并样本方差 (Pooled Variance)：

$$S_p^2=\frac{(n_1-1)S_1^2+(n_2-1)S_2^2}{n_1+n_2-2}$$

   检验统计量严格服从：

$$t=\frac{(\bar{X}_1-\bar{X}_2)-\Delta_0}{S_p\sqrt{\frac{1}{n_1}+\frac{1}{n_2}}}\sim t(n_1+n_2-2)$$

2. **异方差假定 (Welch's t-Test，消除 Behrens-Fisher 问题)**：直接采用各组样本方差：

$$t=\frac{(\bar{X}_1-\bar{X}_2)-\Delta_0}{\sqrt{\frac{S_1^2}{n_1}+\frac{S_2^2}{n_2}}}\overset{\text{近似}}{\sim}t(df^*)$$

   自由度由 **Welch–Satterthwaite 两矩匹配法**近似确定：

$$df^*=\frac{\left(\frac{S_1^2}{n_1}+\frac{S_2^2}{n_2}\right)^2}{\frac{(S_1^2/n_1)^2}{n_1-1}+\frac{(S_2^2/n_2)^2}{n_2-1}}$$

6.4 配对样本 t 检验 (Paired Sample t-Test)

- **降维机制**：对非独立联合正态向量 $(X_{1i},X_{2i})^\top$，构造标量差值序列 $D_i=X_{1i}-X_{2i}$。
- 差值方差：$\sigma_D^2=\sigma_1^2+\sigma_2^2-2\text{Cov}(X_1,X_2)$。若协方差显著为正，差值方差远小于独立样本方差和，大幅提升检验敏感度。
- 统计量：$t=\frac{\bar{D}-d_0}{S_D/\sqrt{n}}\sim t(n-1)$，自由度为对数减 1。

7. 协方差、相关性与 OLS 回归体系

7.1 协方差与 Pearson 积差相关系数

- **样本协方差**：$S_{XY}=\frac{1}{n-1}\sum_{i=1}^n(X_i-\bar{X})(Y_i-\bar{Y})$。
- **Pearson 相关系数**：

$$r=\frac{S_{XY}}{S_XS_Y}=\frac{\sum(X_i-\bar{X})(Y_i-\bar{Y})}{\sqrt{\sum(X_i-\bar{X})^2\sum(Y_i-\bar{Y})^2}}\in[-1,1]$$

  度量两变量间严格线性相关性，对仿射正变换具有不变性。
- **无相关性假定检验**：

$$H_0:\rho=0\implies t=\frac{r\sqrt{n-2}}{\sqrt{1-r^2}}\sim t(n-2)$$

7.2 经典线性回归假定与 OLS 几何投影

数据生成过程：$Y_i=\beta_0+\beta_1X_i+\varepsilon_i$。矩阵形式 $\boldsymbol{y}=\boldsymbol{X\beta}+\boldsymbol{\varepsilon}$。

- **Gauss-Markov 假定**：(1) 严格外生性 $E[\boldsymbol{\varepsilon}|\boldsymbol{X}]=\boldsymbol{0}$；(2) 球形扰动项 $\text{Var}(\boldsymbol{\varepsilon}|\boldsymbol{X})=\sigma^2\boldsymbol{I}_n$；(3) 设计矩阵满列秩 $\text{rank}(\boldsymbol{X})=p+1$。
- **OLS 正规方程**：极小化残差平方和 $\min_{\boldsymbol{\beta}}\boldsymbol{e}^\top\boldsymbol{e}$，求导可得正规方程 $\boldsymbol{X}^\top\boldsymbol{X}\hat{\boldsymbol{\beta}}=\boldsymbol{X}^\top\boldsymbol{y}$。
- **标量解析解**：

$$\hat{\beta}_1=\frac{\sum(X_i-\bar{X})(Y_i-\bar{Y})}{\sum(X_i-\bar{X})^2}=\frac{S_{XY}}{S_X^2}=r\frac{S_Y}{S_X}$$

$$\hat{\beta}_0=\bar{Y}-\hat{\beta}_1\bar{X}\implies\text{回归超平面必穿透重心点}(\bar{X},\bar{Y})$$

- **正交投影性质**：投影矩阵 $\boldsymbol{P}=\boldsymbol{X}(\boldsymbol{X}^\top\boldsymbol{X})^{-1}\boldsymbol{X}^\top$，残差生成元 $\boldsymbol{M}=\boldsymbol{I}-\boldsymbol{P}$。残差向量 $\boldsymbol{e}=\boldsymbol{My}$ 与列空间正交：$\boldsymbol{X}^\top\boldsymbol{e}=\boldsymbol{0}\implies\sum e_i=0,\ \sum X_ie_i=0$。

7.3 方差分解定理与模型拟合优度

在包含截距项时，向量正交性直接导出平方和分解：

$$\underbrace{\sum_{i=1}^n(Y_i-\bar{Y})^2}_{SST\ (\text{总离差平方和})}=\underbrace{\sum_{i=1}^n(\hat{Y}_i-\bar{Y})^2}_{SSR\ (\text{回归平方和})}+\underbrace{\sum_{i=1}^ne_i^2}_{SSE\ (\text{残差平方和})}$$

- **判定系数**：$R^2=\frac{SSR}{SST}=1-\frac{SSE}{SST}$。一元回归下严格满足 $R^2=r^2$。
- **回归标准误 (RSE)**：$s_e=\sqrt{MSE}=\sqrt{\frac{SSE}{n-p-1}}$。
- **修正拟合优度 (Adjusted R^2)**：

$$R^2_{\text{adj}}=1-\frac{SSE/(n-p-1)}{SST/(n-1)}=1-(1-R^2)\frac{n-1}{n-p-1}$$

  惩罚自由度损失；R^2_{adj} 不必然随自变量增加而单调上升。

7.4 多元回归参数推断与偏效应

多元模型：$Y_i=\beta_0+\sum_{j=1}^p\beta_jX_{ij}+\varepsilon_i$。$(Y=X\beta+\varepsilon)$

- $\hat{\beta}=(X^\top X)^{-1}X^\top Y$
- **偏效应语义**：$\hat{\beta}_j=\frac{\partial\hat{Y}}{\partial X_j}$，指控制其余 $p-1$ 个自变量固定不变时，变量 X_j 边际变动对 Y 的条件期望净效应。
- **估计量方差**：$\text{Var}(\hat{\boldsymbol{\beta}}|\boldsymbol{X})=\sigma^2(\boldsymbol{X}^\top\boldsymbol{X})^{-1}$。对单一参数：

$$\text{SE}(\hat{\beta}_j)=\frac{s_e}{\sqrt{\sum(X_{ij}-\bar{X}_j)^2(1-R_j^2)}}$$

  其中 R_j^2 为 X_j 对其余所有自变量回归的辅助判定系数。
- **系数显著性 t 检验**：

$$H_0:\beta_j=0\implies t=\frac{\hat{\beta}_j}{\text{SE}(\hat{\beta}_j)}\sim t(n-p-1)$$