

1. 实证法学方法论与因果推断架构

1.1 事实学转向与休谟二分定理

- **休谟准则 (Hume's Guillotine)**: 严格区隔 “实然” (Is, 经验事实) 与 “应然” (Ought, 规范价值)。从纯粹事实前提不能演绎出规范结论; 规范有效性亦不等于实效性。
- **实证法学的论证功能**:
 - **描述性论证**: 识别司法场域的总体经验分布 (如量刑基准、法官群体裁判均值与离散度)。
 - **目的论证 (Teleological)**: 评估法规规范配置能否有效达成刑罚威慑、犯罪预防等立法目的。
 - **结果论证 (Consequential)**: 识别制度运行的负外部性与意外后果 (如重刑带来的残忍化效应)。

1.2 潜在结果模型与因果识别策略

- **鲁宾因果模型 (Rubin Causal Model)**: 设处理变量 $D_i \in \{0, 1\}$, 个体 i 的潜在结果为 $Y_i(1), Y_i(0)$ 。观测结果为 $Y_i = D_i Y_i(1) + (1 - D_i) Y_i(0)$ 。
- **选择偏差分解**:
$$E[Y|D=1] - E[Y|D=0] = \underbrace{E[Y(1) - Y(0) | D=1]}_{\text{处理组平均效应 (ATT)}} + \underbrace{\{E[Y(0)|D=1] - E[Y(0)|D=0]\}}_{\text{选择偏差 (Selection Bias)}}$$
- **随机对照实验 (RCT)**: 通过随机分配实现协变量平衡 $D \perp (Y(1), Y(0))$, 选择偏差期望为零。司法应用受制于正当程序与伦理。
- **准实验 (Quasi-Experiments)**: 利用外生冲击 (如指定辩护全覆盖试点、选举周期治安官扩招), 采用 DID、断点回归 (RD)、倾向得分匹配 (PSM) 剥离混杂偏误。

2. 测度理论与数据生成机制

2.1 变量测度等级体系

从低阶到高阶递进, 高阶变量包含低阶变量的全部代数信息:

1. **定类 (Nominal)**: 仅满足等价关系 ($=, \neq$)。支持众数统计、列联表卡方检验与哑变量转换 (如性别、罪名类型)。
2. **定序 (Ordinal)**: 满足全序关系 ($<, >$), 但距离非等距。支持秩次与中位数, 差值无运算意义 (如李克特量表、伤情等级)。
3. **定距 (Interval)**: 具有等距单位, 差值具代数意义, **无绝对真零点** (零点为任意人为标定, 如摄氏温度)。
4. **定比 (Ratio)**: 具有等距单位且**具备绝对自然零点** (零代表属性完全缺失), 支持乘除比率运算 (如刑期、罚金额、酒精浓度)。

2.2 数据集的时间维度分类

- **横截面数据 (Cross-sectional)**: 单一时点 t 对 n 个独立个体的静态切片 $\{Y_i, X_i\}_{i=1}^n$ 。
- **重复横截面 (Pooled Cross-sectional)**: 不同时间点独立抽样, 个体不跨期重合。用于评估改革前后的平均处理效应。
- **时间序列数据 (Time Series)**: 单一个体在离散时间轴上的连续观测 $\{Y_t\}_{t=1}^T$ 。
- **面板数据 (Panel Data)**: 追踪相同截面个体在连续时期的复合观测 $\{Y_{it}, X_{it}\}_{i=1, t=1}^{n, T}$ 。

2.3 抽样设计理论

- **简单随机抽样 (SRS)**: 样本入选概率相同且完全独立。
- **分层抽样 (Stratified Sampling)**: 层内同质、层间异质, 按比例配额。严格消除层间变异带来的抽样误差。
- **整群抽样 (Cluster Sampling)**: 群间同质、群内异质。群内聚类相关性会导致有效样本容量萎缩, 须调整聚类标准误。

3. 描述性统计量与点估计理论

3.1 集中趋势与偏度法则

设样本观测序列为 $X_1, X_2, \dots, X_n$:

- **样本均值**: $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 。满足 $E[\bar{X}] = \mu$, 为总体均值的一致最小方差无偏估计 (UMVUE)。易受极端值拖拽。
- **样本中位数 (Median)**: 稳健统计量, 崩溃点 (Breakdown Point) 达 50%。
- **偏度分布测度 (Skewness)**:
 - 正偏 (右偏, 长尾在右侧, 如财产刑罚金): $\text{Mode} < \text{Median} < \text{Mean}$
 - 对称单峰分布 (正态): $\text{Mean} = \text{Median} = \text{Mode}$
 - 负偏 (左偏, 长尾在左侧): $\text{Mean} < \text{Median} < \text{Mode}$

3.2 离散程度与 Bessel 修正证明

- **总体方差 vs 样本方差**:

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^N (X_i - \mu)^2, \quad S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

- **无偏性证明**: 展开离差平方和恒等式:

$$\sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=1}^n (X_i - \mu)^2 - n(\bar{X} - \mu)^2$$

两端求期望, 利用 $E[(X_i - \mu)^2] = \sigma^2$ 以及 $\text{Var}(\bar{X}) = E[(\bar{X} - \mu)^2] = \frac{\sigma^2}{n}$:

$$E \left[\sum_{i=1}^n (X_i - \bar{X})^2 \right] = n\sigma^2 - n \left(\frac{\sigma^2}{n} \right) = (n-1)\sigma^2$$

故 $E[S^2] = \frac{1}{n-1} (n-1)\sigma^2 = \sigma^2$ 。分母扣除 1 自由度消除低估偏差。

- **仿射变换性质**: 若 $Y = aX + b$, 则 $\bar{Y} = a\bar{X} + b$, $S_Y = |a|S_X$, $S_Y^2 = a^2 S_X^2$ 。
- **标准分化 (Z-Transformation)**: $Z_i = \frac{X_i - \mu}{\sigma}$, 具有性质 $E[Z_i] = 0, \text{Var}(Z_i) = 1$ 。

4. 大数定律、中心极限定理与区间估计

4.1 正态分布代数性质与分位数

随机变量 $X \sim \mathcal{N}(\mu, \sigma^2)$, 累积分布函数为 $\Phi\left(\frac{x-\mu}{\sigma}\right)$ 。

- 对称性质: $\Phi(-z) = 1 - \Phi(z)$ 。
- 经验法则: $P(|X - \mu| \leq 1\sigma) \approx 0.6827$; $P(|X - \mu| \leq 1.96\sigma) \approx 0.9500$; $P(|X - \mu| \leq 2.576\sigma) \approx 0.9900$ 。

4.2 渐近收敛理论 (CLT & Slutsky 定理)

- **Lindeberg-Lévy 中心极限定理**: 设 $X_1, \dots, X_n \stackrel{i.i.d.}{\sim} (\mu, \sigma^2)$ ($0 < \sigma^2 < \infty$), 当 $n \rightarrow \infty$ 时:

$$\sqrt{n}(\bar{X}_n - \mu) \xrightarrow{d} \mathcal{N}(0, \sigma^2) \iff \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} \mathcal{N}(0, 1)$$

- **Slutsky 渐近替代定理**: 由大数定律 $S_n \xrightarrow{P} \sigma$, 根据 Slutsky 定理:

$$Z = \frac{\bar{X}_n - \mu}{S_n/\sqrt{n}} = \left(\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \right) \cdot \left(\frac{\sigma}{S_n} \right) \xrightarrow{d} \mathcal{N}(0, 1)$$

在大样本下, 即使总体非正态, 构造的标准误仍能保证渐近正态推断。

- **标准误 (Standard Error)**: $\text{SE}(\bar{X}) = \frac{\sigma}{\sqrt{n}}$, if σ 已知, otherwise 用 S_n 替代。反映估计量自身的抽样方差, 以速率 $O(n^{-1/2})$ 随样本量收敛。

4.3 枢轴量法构造置信区间

- **数理构造**: 构造枢轴量 (有其分布, 不依赖于参数) $Q(\mathbf{X}, \mu) = \frac{\bar{X} - \mu}{S/\sqrt{n}}$ 。双侧 $100(1 - \alpha)\%$ 置信区间为满足 $P(c_1 \leq Q \leq c_2) = 1 - \alpha$ 的解:

$$\text{CI}_{1-\alpha}(\mu) = \left[\bar{X} - z_{\alpha/2} \frac{S}{\sqrt{n}}, \quad \bar{X} + z_{\alpha/2} \frac{S}{\sqrt{n}} \right]$$

- **频率学派概率语义**: 区间端点 $[L(\mathbf{X}), U(\mathbf{X})]$ 是随机变量, 真实参数 μ 是固定常数。在无限次重复抽样生成的区间序列中, 覆盖真值 μ 的频率收敛于 $1 - \alpha$ 。

5. 假设检验理论与 Neyman-Pearson 范式

5.1 参数空间划分与反证推断

- 参数空间严格正交分解: $\Theta = \Theta_0 \cup \Theta_a$, 且 $\Theta_0 \cap \Theta_a = \emptyset$ 。

- 原假设 $H_0: \theta \in \Theta_0$; 备择假设 $H_a: \theta \in \Theta_a$ 。
- 检验统计量 $T(\mathbf{X})$ 将样本空间映射至实数轴，基于预设的拒绝域 $\mathcal{W}$ 给出二元推断规则: $T(\mathbf{x}) \in \mathcal{W} \iff$ 拒绝 H_0 。

5.2 两类错误、势函数与决策控制

定义检验的势函数 (Power Function) 为 $\pi(\theta) = P_\theta(\mathbf{X} \in \mathcal{W})$ 。

统计决策	H_0 为真 ($\theta \in \Theta_0$)	H_a 为真 ($\theta \in \Theta_a$)
接受 H_0	正确接受 ($1 - \alpha$)	II 类错误: 取伪 ($\beta(\theta)$)
拒绝 H_0	I 类错误: 弃真 (α)	检验功效 (Power): $1 - \beta(\theta)$

- 显著性水平控制:** $\sup_{\theta \in \Theta_0} \pi(\theta) \leq \alpha$ 。在优先控制 I 类错误概率的前提下，最大化功效 $1 - \beta$ 。
- 两类错误权衡:** 样本量 n 固定时, $\alpha \downarrow \implies \beta \uparrow$ 。唯一能同步压低 α 与 β 的路径是增加样本容量 n 。

5.3 p-值与对偶定理

- p-值的测度论定义:** 在零假设为真的概率测度下，检验统计量比实际观测值更极端的上确界概率:

$$p\text{-value} = P_{H_0}(|T| \geq |t_{\text{obs}}|)$$

若 H_0 为真且统计量连续，则随机变量 $P \sim \text{Uniform}(0, 1)$ 。

- 对偶定理 (Duality Theorem):** 在显著性水平 α 下，非拒绝域等于置信水平为 $1 - \alpha$ 的置信集合之集:

$$\text{未拒绝 } H_0: \theta = \theta_0 \iff \theta_0 \in \text{CI}_{1-\alpha}$$

6. t 检验数理体系 (Student's & Welch)

6.1 Student's t 分布构造

若 $Z \sim \mathcal{N}(0, 1)$, $V \sim \chi^2(k)$, 且 $Z \perp V$, 定义统计量:

$$T = \frac{Z}{\sqrt{V/k}} \sim t(k)$$

对于正态母体样本，由 Cochran 定理，样本均值 $\bar{X} \perp S^2$ 且 $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$ 。将 $Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$ 与 $V = \frac{(n-1)S^2}{\sigma^2}$ 代入，消去未知参数 σ ，即严格导出 $t(n-1)$ 分布。

6.2 单样本 t 检验 (One-Sample t-Test)

- 满足 $X_1, X_2, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2)$, σ 未知
- 假设: $H_0: \mu = \mu_0$ vs $H_a: \mu \neq \mu_0$
- 统计量: $t = \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \sim t(n-1)$
- 临界拒绝准则: $|t| > t_{\alpha/2, n-1}$ 。

6.3 独立双样本 t 检验 (Two-Sample t-Test)

检验两独立正态总体差值: $H_0: \mu_1 - \mu_2 = \Delta_0$ 。

- 方差齐性假定 ($\sigma_1^2 = \sigma_2^2 = \sigma^2$):** 采用合并样本方差 (Pooled Variance):

$$S_p^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}$$

检验统计量严格服从:

$$t = \frac{(\bar{X}_1 - \bar{X}_2) - \Delta_0}{S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t(n_1 + n_2 - 2)$$

- 异方差假定 (Welch's t-Test, 消除 Behrens-Fisher 问题):** 直接采用各组样本方差:

$$t = \frac{(\bar{X}_1 - \bar{X}_2) - \Delta_0}{\sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}} \overset{\text{近似}}{\sim} t(df^*)$$

自由度由 Welch-Satterthwaite 两矩匹配法近似确定:

$$df^* = \frac{\left(\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}\right)^2}{\frac{(S_1^2/n_1)^2}{n_1-1} + \frac{(S_2^2/n_2)^2}{n_2-1}}$$

6.4 配对样本 t 检验 (Paired Sample t-Test)

- 降维机制:** 对非独立联合正态向量 $(X_{1i}, X_{2i})^\top$, 构造标量差值序列 $D_i = X_{1i} - X_{2i}$ 。
- 差值方差: $\sigma_D^2 = \sigma_1^2 + \sigma_2^2 - 2\text{Cov}(X_1, X_2)$ 。若协方差显著为正，差值方差远小于独立样本方差和，大幅提升检验敏感度。
- 统计量: $t = \frac{\bar{D} - d_0}{S_D/\sqrt{n}} \sim t(n-1)$, 自由度为对数减 1。

7. 协方差、相关性与 OLS 回归体系

7.1 协方差与 Pearson 积差相关系数

- 样本协方差:** $S_{XY} = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})$ 。
- Pearson 相关系数:**

$$r = \frac{S_{XY}}{S_X S_Y} = \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum (X_i - \bar{X})^2 \sum (Y_i - \bar{Y})^2}} \in [-1, 1]$$

度量两变量间严格线性相关性，对仿射正变换具有不变性。

- 无相关性假定检验:**

$$H_0: \rho = 0 \implies t = \frac{r\sqrt{n-2}}{\sqrt{1-r^2}} \sim t(n-2)$$

7.2 经典线性回归假定与 OLS 几何投影

数据生成过程: $Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$ 。矩阵形式 $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$ 。

- Gauss-Markov 假定:** (1) 严格外生性 $E[\boldsymbol{\varepsilon}|\mathbf{X}] = \mathbf{0}$; (2) 球形扰动项 $\text{Var}(\boldsymbol{\varepsilon}|\mathbf{X}) = \sigma^2 \mathbf{I}_n$; (3) 设计矩阵满秩秩 $\text{rank}(\mathbf{X}) = p + 1$ 。
- OLS 正规方程:** 极小化残差平方和 $\min_{\boldsymbol{\beta}} \mathbf{e}^\top \mathbf{e}$, 求导可得正规方程 $\mathbf{X}^\top \mathbf{X} \hat{\boldsymbol{\beta}} = \mathbf{X}^\top \mathbf{y}$ 。
- 标量解析解:**

$$\hat{\beta}_1 = \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{\sum (X_i - \bar{X})^2} = \frac{S_{XY}}{S_X^2} = r \frac{S_Y}{S_X}$$

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X} \implies \text{回归超平面必穿透重心点}(\bar{X}, \bar{Y})$$

- 正交投影性质:** 投影矩阵 $\mathbf{P} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top$, 残差生成元 $\mathbf{M} = \mathbf{I} - \mathbf{P}$ 。残差向量 $\mathbf{e} = \mathbf{M}\mathbf{y}$ 与列空间正交: $\mathbf{X}^\top \mathbf{e} = \mathbf{0} \implies \sum e_i = 0, \sum X_i e_i = 0$ 。

7.3 方差分解定理与模型拟合优度

在包含截距项时，向量正交性直接导出平方和分解:

$$\underbrace{\sum_{i=1}^n (Y_i - \bar{Y})^2}_{SST \text{ (总离差平方和)}} = \underbrace{\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2}_{SSR \text{ (回归平方和)}} + \underbrace{\sum_{i=1}^n e_i^2}_{SSE \text{ (残差平方和)}}$$

- 判定系数:** $R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}$ 。一元回归下严格满足 $R^2 = r^2$ 。
- 回归标准误 (RSE):** $s_e = \sqrt{MSE} = \sqrt{\frac{SSE}{n-p-1}}$ 。
- 修正拟合优度 (Adjusted R^2):**

$$R_{\text{adj}}^2 = 1 - \frac{SSE/(n-p-1)}{SST/(n-1)} = 1 - (1 - R^2) \frac{n-1}{n-p-1}$$

惩罚自由度损失; R_{adj}^2 不必然随自变量增加而单调上升。

7.4 多元回归参数推断与偏效应

多元模型: $Y_i = \beta_0 + \sum_{j=1}^p \beta_j X_{ij} + \varepsilon_i$ 。(或写作上一节的矩阵形式)

- 偏效应语义:** $\hat{\beta}_j = \frac{\partial \hat{Y}}{\partial X_j}$, 指控制其余 $p-1$ 个自变量固定不变时，变量 X_j 边际变动对 Y 的条件期望净效应。
- 估计量方差:** $\text{Var}(\hat{\beta}|\mathbf{X}) = \sigma^2(\mathbf{X}^\top \mathbf{X})^{-1}$ 。对单一参数:

$$\text{SE}(\hat{\beta}_j) = \frac{s_e}{\sqrt{\sum (X_{ij} - \bar{X}_j)^2 (1 - R_j^2)}}$$

其中 R_j^2 为 X_j 对其余所有自变量回归的辅助判定系数。

- 系数显著性 t 检验:**

$$H_0: \beta_j = 0 \implies t = \frac{\hat{\beta}_j}{\text{SE}(\hat{\beta}_j)} \sim t(n-p-1)$$